

Analyse et Modélisation des Elections en France

Rapport de projet de mention SDI de 3^e année

2025-2026



Encadrant de projet : Damien Challet
Membre du groupe : Lucas Lacampagne, Khelil Tabanne, Yann
Chauvard

Remerciements

Nous remercions Damien Challet pour son accompagnement et les précieux conseils qu'il aura su nous donner tout au long du projet.

Nous remercions Julia Cagé, Thomas Piketty et toutes les personnes qui ont travaillé à l'agrégation de ces données [PIKETTY et CAGÉ, 2023].

Nous remercions Street Press et Alessio Motta pour leur travail inspirant sur ce simulateur [ALESSIO, 2026]. Les bonnes prédictions obtenues grâce à celui-ci nous ont permis de croire dans le fait que l'on ne s'engageait pas dans une impasse.

Table des matières

1	Introduction	1
2	Description des données	3
2.1	Données socio-économiques et élections nationales, communales	3
2.2	Données élections européennes	4
3	Modèles et outils	5
3.1	Sélection des variables	5
3.2	Gestion des données : <code>DataHandler</code>	8
3.3	Encapsulation des modèles : <code>RegressorWrapper</code>	9
3.4	Forêt aléatoire et forêt aléatoire oblique	10
3.5	Validation croisée adaptée aux données électorales	12
3.6	Wrapper de séries temporelles : <code>TimeSeriesWrapper</code>	13
4	Test théorie des réalignements	16
4.1	Motivation	16
4.2	Introduction à la théorie des réalignements	16
4.3	Méthodologie du test	17
4.4	Résultats	19
4.4.1	1962-1981	19
4.4.2	1984-2007	20
4.4.3	2007-2022	22
4.4.4	Matrice récapitulative des erreurs	23
4.4.5	Conclusion partielle	23
5	Etude des enjeux électoraux	25
5.1	Évolution des enjeux électoraux au cours du temps	25
5.2	Rôle des variables géographiques et temporelles	31
5.3	Enjeux locaux du vote d'extrême droite	37
5.3.1	Un peu de contexte sociologique	37

5.3.2	Méthodologie du test	38
5.3.3	Résultats	39
5.3.4	Discussion	41
6	Conclusion	43
	Références	44

1 Introduction

A l’intersection entre la sociologie et les sciences politiques, les élections sont une thématique largement étudiée au sein des sciences sociales, et, par la solennité que leur donne nos démocraties occidentales, ont l’avantage d’attirer l’attention générale sur ces disciplines. C’est également le lieu de véritables photographies des préférences électorales à l’échelle nationale, habituellement inaccessible de manière précise. Si longtemps les sciences sociales ont été astreintes à l’analyse descriptive et théorique, le développement récent des méthodes d’apprentissage automatique ouvre de nouvelles perspectives pour tester quantitativement ces théories à grande échelle.

Ce projet s’inscrit à cette intersection entre science politique et science des données. En mobilisant des données électorales et socio-économiques sur près d’un siècle, nous avons pour ambition de mettre à l’épreuve des théories issues de la littérature en science politique afin d’affiner l’analyse des déterminants du vote en France, leur évolution au cours du temps et leurs spécificités régionales.

Un premier travail d’agrégation des données électorales française et des données socio-économiques correspondantes à l’échelle communale, ainsi qu’une analyse des déterminants de vote, est réalisé par PIKETTY et CAGÉ, [2023](#), et sur lequel nous prenons appui. Si les données électorales depuis le début du siècle sont facilement accessible (DATAGOUV, [2026](#)), les auteurs proposent une riche base de données incluant des centaines d’indicateurs socio-économiques et de résultats de vote remontant au XIX^e siècle, essentielle pour une analyse de l’évolution des dynamique électorales françaises. Nous complétons ces données par les résultats des élections européennes de 1999 à 2024 suivant la même classification politique.

Du côté de l’analyse politique, d’autres travaux tendent à nuancer la recherche d’une loi générale entre condition socio-économique et vote, en mettant en avant la non-stationnarité des dynamiques électorales sur le temps long, notamment par la théorie des réalignements (MARTIN, [2000](#), GOUGOU et MARTIN, [2013](#), LABOURET, [2014](#), GOUGOU, [2024a](#), GOUGOU, [2024b](#)). Dans la dimension spatiale également la littérature met en avant des divergences géographiques : à travers leurs enquêtes de terrain sur le même corps électoral dans deux

régions différentes, COQUARD, 2019 et FAURY, 2024 soulignent les spécificités locales parfois contraires entre régions dans la détermination du vote.

Notre objectif est donc, au delà d’une simple analyse *data-driven* de la relation entre les variables socio-économiques et le résultat des élections, de s’appuyer sur les sciences sociales et de tenter de faire le pont avec la sciences des données, en testant quantitativement les théories abordées précédemment, et qui n’ont pas fait l’objet d’une telle analyse dans la littérature.

Sur le plan méthodologique, nous avons construit un pipeline complet de modélisation reposant sur la forêt aléatoire (*Random Forest*), dont nous détaillons les choix de conception : sélection des variables par information mutuelle et contrôle de la multicollinéarité, validation croisée adaptée à la structure temporelle des données électorales, et mesure de l’importance des variables par permutation.

Ce rapport est organisé en quatre parties principales. Après une description des données mobilisées (**Section 2**) et une présentation de l’architecture logicielle et des choix méthodologiques (**Section 3**), nous testons quantitativement la théorie des réalignements électoraux sur les élections législatives de la Cinquième République (**Section 4**). Nous analysons ensuite l’évolution des enjeux électoraux au cours du temps, le rôle des variables géographiques et les déterminants locaux du vote d’extrême droite dans les régions Nord, Grand Est et PACA (**Section 5**). Le code source de ce projet est disponible à [ce lien](#).

2 Description des données

2.1 Données socio-économiques et élections nationales, communales

Nous utilisons les données mises à disposition sur le site Une histoire du conflit politique et les données mises en ligne par Thomas Piketty et Julia Cagé [PIKETTY et CAGÉ, 2023]. Ce site regroupe les résultats électoraux de plusieurs élections, notamment les élections présidentielles de la Vème République, l'élection présidentielle de la Deuxième République en 1848, ainsi que divers référendums. Parmi ces référendums, on trouve ceux de 1793 (Constitution de l'An I), 1795 (Constitution de l'An III et décret des deux tiers), 1946 (Constitution de la IVème République), 1992 (Traité de Maastricht) et 2005 (projet de constitution européenne). Le site inclut également les résultats des élections législatives de la Deuxième République (à l'exception de 1852), de la Troisième République (à l'exception de 1877), de la Quatrième République et de la Cinquième République (à l'exception de 2024).

L'ensemble des résultats électoraux est décliné au niveau de la commune, ce qui signifie que nous disposons des résultats pour chaque commune. Les résultats ont été obtenus à partir de diverses sources. D'une part, la numérisation des procès-verbaux des élections conservés aux Archives nationales a permis de fournir des données électorales jusqu'à présent indisponibles sous forme numérique. D'autre part, les données du Ministère de l'Intérieur, disponibles sous forme numérique pour les élections postérieures à 1993, ont également été utilisées.

Les auteurs des données ont procédé à des classifications politiques que nous reprenons. La première classification est la division "bloc de gauche / bloc de droite", où les variables 'TG' et 'TD' répartissent les voix entre les partis de gauche et les partis de droite, les voix des partis centristes étant divisées équitablement entre ces deux blocs. Une deuxième classification divise les voix en trois blocs : un bloc 'gauche + centre-gauche' ('GGC'), un bloc centre ('C') et un bloc 'droite + centre-droite' ('DCD'). Enfin, une troisième classification répartit les voix en cinq blocs politiques : 'G', 'CG', 'C', 'CD', 'D'. La détermination des tendances politiques a été réalisée grâce aux données du ministère de l'Intérieur et du journal Le Monde, qui décline les résultats par tendance politique pour les élections récentes, puis en confrontant

les résultats à la presse de l'époque pour les élections les plus anciennes.

2.2 Données élections européennes

Motivons la démarche. Nous avons rapidement tenté de prédire certaines composantes du vote (participation, vote à droite, gauche...) et en particulier du vote aux élections législatives [compléter : pk]. N'arrivant dans un premier temps pas vraiment à obtenir de résultats satisfaisants, nous avons voulu tester l'influence du nombre de points réduit pour chaque commune. Une série temporelle qui décrit l'évolution du vote à droite aux législatives dans une commune donnée entre les années 1981 et 2017 fait seulement 9 points.

Lors des élections européennes de 2024, le Rassemblement National (RN) réalise une percée historique en raflant plus de 7.7 millions de voix [LESUEUR, 2024]. Les élections législatives anticipées qui suivirent la dissolution de l'Assemblée Nationale par le Président de la République sont marquées par cette même dynamique, avec des très bons résultats pour le RN. Cet exemple nous fait sentir que les résultats des élections européennes peuvent contenir de l'information intéressante pour prédire ce qui se passe aux législatives. Leurs dates - généralement à mi-chemin entre deux élections législatives - a aussi des chances d'en faire des points intéressants à rajouter dans les données.

Nous avons donc agrégé les données des élections européennes de 1999 à 2024 au niveau communal en suivant la même classification des tendances politiques que dans les données précédentes. Elles n'ont pas suffi à classer les listes européennes, qui ne sont pas toutes liées directement à des partis politiques nationaux - régionalistes, chasseurs, animalistes, souverainistes... Nous avons donc rajouté quelques classifications quand elles étaient évidentes et que des recherches simples permettaient de statuer sur des liens forts avec une certaine tendance. Comme Cagé et Piketty, nous avons réparti les voix restantes uniformément entre les tendances. Les scripts ayant permis cette agrégation sont disponibles sur le Github du projet.

3 Modèles et outils

Cette section décrit l’architecture logicielle et les choix méthodologiques qui sous-tendent l’ensemble du pipeline de prédiction. Nous présentons successivement la sélection des variables, le traitement des données, l’encapsulation des modèles et le choix de la forêt aléatoire comme estimateur de base.

3.1 Sélection des variables

Le jeu de données brut agrège des indicateurs socio-économiques issus de sources administratives françaises à l’échelle communale : revenus et PIB (`pibcommunes`), capital immobilier (`capitalimmobiliercommunes`), structure démographique (`agesexcommunes`), niveau de diplôme (`diplomescommunes`), catégorie socio-professionnelle (`cspcommunes`), mobilité domicile-travail (`popcommunes`) et parc de logements (`proprietairescommunes`). Ce large éventail de variables brutes nécessite une étape de sélection rigoureuse avant toute modélisation, afin d’éliminer les redondances et les variables non informatives.

La sélection s’opère en deux temps :

Filtrage par information mutuelle (MI). L’information mutuelle mesure la dépendance statistique entre chaque variable explicative X_j et la cible y (taux de vote), sans hypothèse de linéarité. Pour des variables continues, elle est estimée à partir des k plus proches voisins dans l’espace joint (estimateur de Kraskov), ce qui correspond à l’implémentation `mutual_info_regression` de scikit-learn :

$$I(X_j ; y) = \iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy. \quad (1)$$

Les variables dont le score MI est inférieur à un seuil fixé sont écartées. Ce filtre non paramétrique est particulièrement adapté au contexte électoral, où les effets de seuil et les interactions non linéaires sont fréquents : une relation entre niveau de diplôme et vote peut être fortement non monotone sans être captée par un simple coefficient de corrélation de Pearson.

Contrôle de la multicollinéarité par le VIF. Sur le sous-ensemble retenu par le filtre MI, on calcule le *Variance Inflation Factor* (VIF) pour chaque variable :

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad (2)$$

où R_j^2 est le coefficient de détermination de la régression de X_j sur toutes les autres variables. Un VIF élevé (> 10 en règle générale) indique une redondance forte avec d'autres prédicteurs, ce qui nuit à la stabilité des estimateurs et à l'interprétation des importances de variables. Les variables dépassant ce seuil sont supprimées de manière itérative jusqu'à ce que la multicollinéarité résiduelle soit acceptable.

À l'issue du filtrage par information mutuelle, les $n = 50$ variables présentant le score MI le plus élevé sont conservées. Sur ce sous-ensemble, le VIF est calculé de manière itérative et les variables dont le VIF dépasse le seuil de 10 sont supprimées une à une jusqu'à ce que toutes les variables restantes satisfassent cette contrainte. Ce seuil de 10 est le critère standard dans la littérature économétrique et s'est révélé suffisant pour éliminer les redondances les plus fortes tout en préservant un ensemble de variables riche et interprétable.

À l'issue du pipeline MI-VIF, les 19 variables suivantes ont été retenues. Le Tableau 1 en présente la liste ainsi qu'une description synthétique. Les variables géographiques (`long`, `lat`) sont incluses dans le jeu de features par défaut ; leur impact spécifique est analysé séparément en section 5.2.

TABLEAU 1 – Variables socio-économiques retenues après filtrage MI ($n = 50$) et VIF (< 10).

Variable	Catégorie	Description
<code>pibcommunes/pibtot_pctchange</code>	Économique	Variation relative du PIB communal
<code>pibcommunes/pibtot</code>	Économique	PIB total de la commune
<code>pibcommunes/pibtot_delta</code>	Économique	Variation absolue du PIB communal

Suite page suivante...

Variable	Catégorie	Description
capitalimmobiliercommunes/capitalratio_pctchange	Patrimoine	Variation du ratio capital immobilier / revenu
capitalimmobiliercommunes/capitalratioagglo_pctchange	Patrimoine	Variation du ratio capital immobilier à l'échelle de l'agglomération
capitalimmobiliercommunes/capitalimmo	Patrimoine	Stock de capital immobilier communal
capitalimmobiliercommunes/capitalimmoagglo_delta	Patrimoine	Variation du capital immobilier à l'échelle de l'agglomération
proprietairescommunes/nlogement	Patrimoine	Nombre de logements dans la commune
diplomescommunes/supf_rank	Éducation	Rang de la commune selon la part de femmes diplômées du supérieur
diplomescommunes/suph_rank	Éducation	Rang de la commune selon la part d'hommes diplômés du supérieur
cspcommunes/cadr_rank	CSP	Rang de la commune selon la part de cadres et professions intellectuelles
cspcommunes/capi_rank	CSP	Rang de la commune selon la part d'agriculteurs exploitants
agesexcommunes/popf	Démographie	Population féminine de la commune
agesexcommunes/popm	Démographie	Population masculine de la commune
popcommunes/peragglo	Mobilité	Part de la population résidant dans une agglomération
popcommunes/percommu	Mobilité	Part de la population effectuant des trajets domicile-travail
popcommuneselecteurs/electeurs_rank	Électorale	Rang de la commune selon le nombre d'électeurs inscrits
long	Géographique	Longitude de la commune
lat	Géographique	Latitude de la commune

3.2 Gestion des données : DataHandler

L'ensemble des opérations de chargement, de filtrage et de découpage du jeu de données est centralisé dans la classe `DataHandler`. Cette architecture permet de garantir la reproductibilité des expériences et d'éviter toute fuite d'information (*data leakage*) entre les ensembles d'entraînement et de test.

Chargement efficace par *predicate pushdown*. Le jeu de données complet est stocké au format Parquet, un format colonnaire optimisé pour les requêtes analytiques. La méthode `load_data` exploite le moteur PyArrow pour appliquer les filtres directement au niveau du fichier, sans charger l'intégralité des données en mémoire :

```
df = pd.read_parquet(
    path, engine="pyarrow",
    filters=[
        ("type", "=", type_election),
        ("annee", ">=", starting_year),
        ("annee", "<=", last_year),
    ],
    columns=features,
)
```

Cette technique de *predicate pushdown* réduit significativement les transferts mémoire en filtrant les lignes et les colonnes inutiles avant même leur désérialisation. Elle est particulièrement bénéfique lorsque l'on itère sur de nombreuses fenêtres temporelles lors du benchmark.

Après chargement, la méthode `prepare_data` élimine les colonnes dont le taux de valeurs manquantes dépasse un seuil configurable `missing_data_thresh`, assurant ainsi la qualité du jeu de données sans imputation.

Découpage temporel sans fuite. La méthode `split_train_test` implémente une séparation stricte fondée sur l'année : l'ensemble d'entraînement contient toutes les élections antérieures à `l_year`, tandis que l'ensemble de test est exclusivement composé des observations de `l_year`. Ce choix est motivé par la nature temporelle des données : un découpage aléatoire au niveau commune mélangerait des années dans les deux ensembles, laissant fuiter de l'information future vers l'entraînement.

Agrégation départementale. La méthode `aggregate_dep` permet de remonter les données à l'échelle départementale par une moyenne pondérée par la population :

$$\bar{x}_{\text{dep},t} = \frac{\sum_{c \in \text{dep}} x_{c,t} \cdot \text{pop}_c}{\sum_{c \in \text{dep}} \text{pop}_c}, \quad (3)$$

où c désigne une commune, t une année électorale et pop_c la population communale. Cette formule suppose que les variables agrégées sont des taux ou des ratios ; elle est valide pour l'ensemble des features retenues. Le regroupement est effectué conjointement par département et par année (`groupby(["dep", "annee"])`) afin de ne pas mélanger les résultats d'élections différentes. Un traitement spécifique est appliqué aux départements d'outre-mer dont le code INSEE commence par 97, pour lesquels le code département est extrait sur trois caractères plutôt que deux.

3.3 Encapsulation des modèles : RegressorWrapper

Afin de permettre un benchmark homogène entre différents estimateurs scikit-learn, tous les modèles sont encapsulés dans la classe `RegressorWrapper`, qui hérite de `BaseEstimator` et expose une interface unifiée.

Conception. Le wrapper reçoit à l'instanciation une classe de base (par exemple `RandomForestRegressor`) et ses hyperparamètres sous forme de `kwargs`. Il instancie le modèle sous-jacent et expose les méthodes `fit` et `predict` conformes à l'API scikit-learn. À chaque appel à `fit`, une nouvelle instance du modèle est créée via `clone`, garantissant ainsi une réinitialisation complète de

l'état interne et l'absence d'effets de bord entre les répétitions d'entraînement.

Optimisation des hyperparamètres. La méthode `tune_cv_hyperparams` encapsule une recherche par grille (`GridSearchCV`) avec un découpeur de validation croisée configurable. Par défaut, un `TimeSeriesSplit` est utilisé ; il peut être remplacé par un `ElectionYearCV` personnalisé (décrit en section 3.5) pour une validation temporellement rigoureuse. La variable `annee` est supprimée en tête de pipeline via un `FunctionTransformer` afin qu'elle ne soit jamais utilisée comme variable explicative par l'estimateur lors de la recherche. La grille de recherche est définie extérieurement dans le fichier de configuration du projet :

```
param_grid_rf = {
    "n_estimators":      [200, 500],
    "max_depth":         [6, 10, None],
    "min_samples_leaf":  [5, 10, 20],
    "max_features":      [0.5, 0.75, "sqrt"],
    "min_impurity_decrease": [0.0, 1e-4],
}
```

Importance par permutation. La méthode `compute_permutation_importance` mesure la contribution de chaque variable en évaluant la dégradation de la performance lorsque ses valeurs sont permutées aléatoirement sur l'ensemble de test. Contrairement à l'importance par impureté de Gini, cette méthode est indépendante de la structure interne de l'arbre et fournit une mesure directement interprétable en termes d'impact sur le score. Elle est calculée à l'issue de chaque expérience et constitue le principal outil d'analyse de l'influence des variables socio-économiques. À noter que `annee` doit être absente de `X_test` lors de cet appel lorsque l'on souhaite isoler les effets socio-économiques purs ; cette exclusion est gérée en amont lors de la construction des ensembles de test.

3.4 Forêt aléatoire et forêt aléatoire oblique

Forêt aléatoire standard. La forêt aléatoire est un ensemble d'arbres de décision entraînés sur des sous-échantillons bootstrap du jeu de données, avec une sélection aléatoire des

variables à chaque nœud. La prédiction finale est la moyenne des prédictions individuelles :

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}), \quad (4)$$

où B est le nombre d'arbres et T_b le b -ième arbre. Ce mécanisme de bagging réduit la variance sans augmenter le biais, rendant le modèle robuste aux variations d'échantillonnage—propriété précieuse lorsque l'on compare des communes aux profils socio-économiques très hétérogènes.

Les séparations des nœuds sont réalisées sur des axes alignés sur les variables originales : à chaque nœud, le meilleur seuil τ est cherché pour une seule variable X_j , partitionnant l'espace en $\{X_j \leq \tau\}$ et $\{X_j > \tau\}$. Cette contrainte facilite l'interprétation mais limite la capacité du modèle à capturer des frontières de décision obliques dans l'espace des features.

Forêt aléatoire oblique. Les forêts aléatoires obliques relaxent cette contrainte en permettant des séparations selon des combinaisons linéaires de variables :

$$\mathbf{a}^\top \mathbf{x} \leq \tau, \quad \mathbf{a} \in \mathbb{R}^p, \quad (5)$$

où $\mathbf{a}$ est un vecteur de coefficients appris. Les hyperplans de séparation ne sont plus nécessairement orthogonaux aux axes, ce qui permet de capturer des relations entre variables sans que la profondeur de l'arbre n'explose.

Dans le contexte électoral, cette propriété est particulièrement pertinente : l'effet d'un fort taux de diplômés supérieurs (X_1) peut dépendre conjointement de la densité de cadres (X_2) et du capital immobilier (X_3), formant une frontière de décision que les arbres à séparations axiales ne peuvent approximer qu'avec de nombreux nœuds supplémentaires. La forêt oblique exprime directement cette interaction en un seul hyperplan $a_1 X_1 + a_2 X_2 + a_3 X_3 \leq \tau$.

L'implémentation utilisée dans ce projet repose sur la bibliothèque `scikit-obliquetree`, qui expose une API compatible `scikit-learn` et s'intègre sans modification dans le `RegressorWrapper` :

```
from oblique_forests import ObliqueRandomForestRegressor

model = RegressorWrapper(
    ObliqueRandomForestRegressor,
    n_estimators=200,
    max_features="sqrt",
    random_state=random_seed,
)
```

Afin de vérifier empiriquement l'apport des séparations obliques dans ce contexte, les deux variantes ont été comparées sur l'ensemble des fenêtres d'évaluation. Les résultats montrent que la forêt oblique n'apporte pas d'amélioration significative par rapport à la forêt standard : les scores R^2 et RMSE sur l'ensemble de test sont pratiquement identiques entre les deux approches. Ce résultat suggère que, pour ce jeu de données, les interactions entre variables socio-économiques ne structurent pas la frontière de décision selon des directions suffisamment obliques pour justifier le surcoût computationnel de la forêt oblique. Par conséquent, la forêt aléatoire standard a été retenue comme estimateur de base pour l'ensemble du benchmark, pour deux raisons supplémentaires : d'une part, son temps d'entraînement est sensiblement inférieur ; d'autre part, la bibliothèque `scikit-obliquetree` ne prenant pas en charge nativement les valeurs manquantes lors de la prédiction, l'implémentation `scikit-learn` constitue un avantage pratique non négligeable sur des données communales historiques dont la couverture peut être incomplète.

3.5 Validation croisée adaptée aux données électorales

La validation croisée standard (k-fold) est inadaptée aux données électorales pour deux raisons. Premièrement, un découpage aléatoire peut placer des communes de la même année dans les ensembles d'entraînement et de validation simultanément, créant une fuite d'information temporelle. Deuxièmement, le `TimeSeriesSplit` de `scikit-learn` opère au niveau des

lignes : sa frontière de découpage peut tomber à l'intérieur d'une même année électorale, mélangeant des communes de la même élection de part et d'autre du pli.

Pour remédier à ces deux problèmes, un découpeur personnalisé `ElectionYearCV` a été implémenté. Il hérite de `BaseCrossValidator` et génère des plis de validation glissants au niveau des années électorales entières :

$$\begin{aligned} \text{Pli 1 : } & \text{Train } [e_1, \dots, e_{k-1}] \longrightarrow \text{Val } e_k \\ \text{Pli 2 : } & \text{Train } [e_1, \dots, e_k] \longrightarrow \text{Val } e_{k+1} \\ & \vdots \end{aligned} \tag{6}$$

où e_i désigne la i -ème élection disponible dans la fenêtre d'entraînement. Les indices retournés par `split()` sont des positions entières (via `np.where`) et non des labels pandas, ce qui évite les erreurs d'indice hors-limites lors de la parallélisation par `joblib`. L'année `annee` est transmise au découpeur via le paramètre `groups` de `GridSearchCV`, conformément à l'API `scikit-learn` ; elle est supprimée par le pipeline interne à `tune_cv_hyperparams` avant d'être transmise à l'estimateur, de sorte qu'elle ne soit jamais vue comme variable explicative.

Dans le cadre de ce projet, la recherche des hyperparamètres optimaux a été conduite sur la fenêtre temporelle 1 988–2 017. Ce choix garantit que les hyperparamètres retenus ne sont pas influencés par les caractéristiques spécifiques de l'élection 2 022, renforçant ainsi la robustesse et la généralisabilité du modèle. Les paramètres optimaux identifiés à l'issue de cette procédure sont : `max_depth = None`, `max_features = "sqrt"`, `min_impurity_decrease = 0.0`, `min_samples_leaf = 10` et `n_estimators = 200`.

3.6 Wrapper de séries temporelles : `TimeSeriesWrapper`

Pour orchestrer les prévisions sur séries temporelles et intégrer les couches d'encapsulation précédentes, la classe `TimeSeriesWrapper` fait office d'interface de haut niveau entre la librairie `MLForecast` (Nixtla) et les instances de `RegressorWrapper`. L'idée à l'époque était de pouvoir utiliser facilement les méthodes Nixtla sur les instances de `RegressorWrapper`. Aujourd'hui, nous aurions tendance à dire à quelqu'un qui reprend notre code de laisser tom-

ber cette partie - dont nous allons tout de même expliquer les choix de conception. En effet, la rigidité de certains test Nixtla et le fait d’avoir deux wrappers a pu souvent nous faire perdre du temps et poser des problèmes techniques, sans apporter vraiment plus que ce que nous avons fait à la main par la suite avec la classe `DataHandler` notamment.

Architecture et intégration. Le wrapper centralise la gestion des métadonnées temporelles (`lags`, fréquences) et des caractéristiques statiques. La méthode `setup_mlf` assure l’initialisation du moteur de prévision en transformant une liste de modèles encapsulés en un dictionnaire nommé. Un mécanisme de suffixe dynamique est implémenté pour permettre l’inclusion simultanée de plusieurs instances d’un même algorithme (par exemple, deux `RandomForest` avec des profondeurs distinctes) sans collision de noms dans l’API Nixtla.

Logique de prévision et exogènes. La génération des prévisions via `run_forecast` suit un protocole rigoureux de reconstruction des données :

- Création d’une grille temporelle future (`make_future_dataframe`) alignée sur l’horizon cible.
- Fusion (*merge*) des variables exogènes issues des données de test, garantissant que les prédictors externes sont disponibles à chaque pas de temps.
- Injection des données transformées dans le modèle pour la prédiction finale, en prenant soin d’isoler les variables statiques conformément aux exigences du pipeline.

Validation croisée et évaluation. Le wrapper expose une méthode `get_cv_rmse` qui automatise le *backtesting* historique. Contrairement à une validation croisée classique, elle utilise `cross_validation` avec le paramètre `refit=True`, forçant ainsi un réentraînement complet sur chaque fenêtre glissante. L’évaluation de la performance est complétée par `evaluate_performance`, qui ventile les métriques ($RMSE$, R^2 , MAE) par année pour identifier d’éventuels biais temporels ou des points atypiques (*outliers*) dans les prédictions électorales.

Analyse globale des importances. Enfin, la méthode `run_all_permutation_importances` boucle sur l’ensemble des modèles entraînés. Elle s’appuie sur le prétraitement de `MLForecast`

pour transformer l'ensemble de test (génération des lags et transformations de la cible) avant de déléguer le calcul de l'importance par permutation aux `RegressorWrapper` sous-jacents. Cette approche permet une comparaison directe et homogène de l'influence des variables à travers tout le catalogue de modèles testés.

4 Test théorie des réalignements

4.1 Motivation

En essayant de prédire les élections futures à partir de celles du passé, au niveau communal, on se rend vite compte que c'est une tâche difficile et que, peu importe que l'on prenne en compte toutes les élections passées ou seulement certaines, on obtient généralement d'assez mauvaises prédictions. Vient alors assez rapidement une question fondamentale : Les variables géographiques et socio-économiques sous-déterminent-elles le vote ? On pourrait croire, par exemple, que certains des déterminants du vote à l'extrême-droite, comme le sentiment de submersion migratoire, le sentiment d'insécurité, soient assez difficiles à comprendre pour un modèle sur la base de ces données - puisque malgré leurs bases matérielles indéniables, il s'agit de sentiments, qui n'ont par définition, pas vraiment de mesure objective.

Aussi, pour prédire le vote, il faut en comprendre les enjeux et savoir les pondérer. Or, les enjeux du vote n'ont rien de stationnaire. Après quelques recherches nous sommes amenés à consulter ces références [LABOURET, 2014, GOUGOU, 2024a, GOUGOU et MARTIN, 2013, MARTIN, 2000] dont la lecture nous aide à comprendre comment la science politique étudie cette idée de non-stationnarité et d'évolution des enjeux électoraux.

Notre formation n'est pas une formation de sciences politiques, aussi j'invite les lecteurs qui pourraient avoir ce bagage à une certaine indulgence, même si nous allons tâcher de rendre compte du mieux possible ce que nous avons compris de cette théorie. L'idée pour la suite du développement de cette partie sera de tester quantitativement cette théorie, avec des méthodes modernes de science des données - Random Forest, Oblique Random Forest.

4.2 Introduction à la théorie des réalignements

Comme expliqué précédemment, les enjeux du conflit politique évoluent au cours du temps. La théorie des réalignements propose globalement de distinguer les périodes de politique ordinaire - soient les périodes sur lesquelles les enjeux sont considérés stables et invariants, ou peu variants - des périodes de réalignement - périodes durant lesquelles les enjeux électoraux changent de façon durable. Un réalignement se déroule durant une ou

plusieurs élections critiques et débouche sur une nouvelle période de politique ordinaire. Il est à noter que la théorie distingue aussi des alignements électoraux, qui sont des sortes de mini-réalignements dans les périodes de politique ordinaire, mais qui ne provoquent pas de changements assez profonds dans les enjeux électoraux pour être considérés comme tels.

MARTIN, 2000 propose une classification des élections en périodes de politique ordinaire et réalignements de 1870 à 2000. LABOURET, 2014 étend ces résultats jusqu'en 2007 ; les travaux GOUGOU et MARTIN, 2013 et GOUGOU, 2024a dessinent les contours des classifications des élections jusqu'en 2022. A noter que l'auteur de ces derniers met bien en garde sur le fait que la confirmation qu'une élection constitue un réalignement ou pas ne peut être obtenue qu'en analysant les résultats des élections suivantes.

4.3 Méthodologie du test

Les variables utilisées ici sont les mêmes que celles sélectionnées dans le tableau 1. On ajoute une feature 'lag', c'est à dire qu'on prédit en sachant les résultats de l'élection précédente - à savoir que nous avons aussi testé de mettre plusieurs lags et de prédire la différence de résultats entre deux élections successives, mais cela pose vite des problèmes puisque notre série temporelle est assez courte, sans améliorer significativement les résultats par rapport à un seul lag. On transforme aussi la variable 'année' en deux variables : un numéro d'élection qui assure qu'elles sont ordonnées correctement et le temps écoulé depuis la dernière élection. Nous avons entraîné un modèle sur une certaine fenêtre au sein d'une période de politique ordinaire, puis nous avons prédit une certaine variable sur les élections précédentes et suivantes avec ce modèle. La variable à prédire est choisie de telle sorte que le changement d'enjeux sur la période étudiée soit visible ; vote à gauche/vote à droite par exemple. On calcule l'erreur sur les prédictions (RMSE) et on obtient une erreur sur la période d'entraînement par cross-validation. L'erreur devrait rester faible sur la période de politique ordinaire sur lequel le modèle a été entraîné - puisque les enjeux y sont invariants - et augmenter sur les périodes de réalignement qui la précèdent et la suivent. Aussi, on pourrait imaginer lisser cette erreur par période et obtenir une mesure de la proximité des enjeux électoraux entre les périodes - accordons nous sur le fait que c'est très peu interprétable, même si cela fournit une

mesure quantifiable à moindre coût. Enfin, nous avons utilisé un modèle de forêt aléatoire plutôt qu'un modèle de forêt aléatoire oblique, pour éviter d'avoir à résoudre les problèmes de données socio-économiques manquantes.

Nous avons fait le choix de conduire nos tests sur les **élections législatives post-1945** seulement ; cela nous permettra déjà de tester cette méthodologie sur deux périodes de politiques ordinaires bien délimitées par la théorie de sciences politiques - 1962-1981 et 1984-2007 - ainsi que sur la période récente - 2007-2022. Aussi, cette période est déjà réductrice puisque nous sommes obligés de ne pas prendre en compte les communes qui ont des résultats d'élections manquants sur la variable qu'on cherche à prédire ; sans quoi on ne peut calculer l'erreur. Ce serait pire si on prédisait pré-1945 ; on aurait encore plus de résultats manquants. On obtient des résultats sur 26000 à 34000 communes suivant les situations.

4.4 Résultats

Les résultats sont tous présentés de la même façon. On trace l'erreur RMSE en ordonnée au cours du temps. Les années d'élections sont représentées par des points, qu'on relie par des lignes arbitraires. La couleur du fond permet de comprendre sur quelle période on se situe. Le fond jaune fait ressortir la période sur laquelle le modèle a été entraîné. Le gris donne à voir les périodes de réalignement et le blanc, les périodes de politique ordinaire.

4.4.1 1962-1981

On se place aux alentours de la période de politique ordinaire 1962-1981 et on choisit une fenêtre d'entraînement qui varie de 3 à 5 élections. On fait le choix de prédire le vote à gauche ici, puisque selon GOUGOU, 2024a et MARTIN, 2000, il semblerait que ce soit dans ce vote-là (SFIO et PC) que les reconfigurations les plus profondes aient eu lieu entre 1981 et 1984 - nous reviendrons plus en détail sur l'évolution précise des enjeux dans une partie dédiée par la suite.

Analysons la figure 1 : le fait d'agrandir la taille de la fenêtre a tendance à réduire la valeur




FIGURE 1 – 1962-1981

absolue de l'erreur RMSE obtenue sur les années d'entraînement par validation croisée. Aussi, on observe que l'erreur RMSE moyennée sur une période (ordinaire ou de réalignement) est la plus basse sur la période sur laquelle le modèle a été entraîné et qu'elle est globalement beaucoup plus élevée sur les autres. Les élections sur la même période de politique ordinaire que l'entraînement et non-utilisées lors de celui-ci (1973 et 1978 sur la courbe rouge, 1978 sur la verte et jaune) sont systématiquement celles qui obtiennent l'erreur RMSE la plus basse. En comparant ces valeurs à celles de l'écart-type sur les données (entre 0.12 et 0.13), il semble donc que notre modèle arrive assez bien à capturer les enjeux sur la période de politique ordinaire sur laquelle il a été entraîné.

D'autre part, on observe systématiquement des erreurs qui doublent à minima en 1981 par rapport à celles obtenues sur l'élection de 1978, semblant confirmer cette idée de changement profond des enjeux dans le vote à gauche, dès 1981. Aussi, les erreurs moyennes obtenues sur la période de réalignement qui précède (1958-1962) sont faibles pour les modèles qui ont été entraînés sur l'année 1962 et plus élevés sinon. Même si la figure jaune semble faire apparaître une erreur similaire entre 1967 et 1981, il n'est pas évident de conclure à un réalignement en 1962.

4.4.2 1984-2007

On se place aux alentours de la période de politique ordinaire 1984-2007 et on choisit une fenêtre d'entraînement qui varie de 3 à 5 élections. On fait le choix de prédire le vote à droite ici, puisque toujours selon GOUGOU, 2024a et MARTIN, 2000, il semblerait que ce soit la stratégie de droitisation sarkozyste qui ait induit des reconfigurations dans les enjeux dès 2007.

Analysons la figure 2 : ici, on observe des ruptures dans les structures électorales encore plus saillantes. On observe un phénomène de "plateau" extrêmement marqué : les prédictions d'avant la période d'entraînement, font s'envoler la RMSE pour atteindre des valeurs situées entre 0.20 et 0.35, soit bien au-delà de l'écart-type des données (0.08 – 0.20). Cela souligne une incapacité quasi totale du modèle à généraliser les enjeux de la période ordinaire aux




FIGURE 2 – 1981-2007

élections antérieures à 1981.

D'autre part, la rupture de 1981 apparaît ici comme un véritable mur électoral. L'erreur chute brutalement, passant d'environ 0.27 en 1978 à 0.05 en 1981 (courbe rouge), ce qui valide l'idée que les variables structurant le vote à droite basculent radicalement à ce moment précis. On note également que l'élargissement de la fenêtre (modèles vert et jaune) stabilise ce "fond de cuve" de l'erreur sur toute la période de consolidation partisane.

Enfin, si le modèle capture bien les enjeux jusqu'en 2002, on observe une remontée systématique de la RMSE à partir de 2007-2012, et plus encore en 2017. Ce décrochage suggère que nous sortons de l'ordre électoral né dans les années 80, les modèles entraînés sur cette période perdant de leur pertinence face aux recompositions plus récentes du paysage politique.




FIGURE 3 – 2007-2022

4.4.3 2007-2022

Le déplacement de la fenêtre d'entraînement vers la période contemporaine (2007-2022) confirme la persistance d'une rupture majeure avec le monde politique pré-1981. On observe que l'erreur RMSE reste massivement élevée jusqu'en 1981-1984, oscillant entre 0.20 et 0.40, ce qui corrobore l'idée d'un changement de paradigme à cette période.

Le déplacement de la période d'entraînement vers les élections récentes semble permettre de capturer de mieux en mieux les enjeux des élections de 2017 et 2022, jusqu'à obtenir une erreur sur 2022 du même ordre de grandeur que sur les années d'entraînement, avec la courbe bleue. En parallèle, l'erreur sur la période post-1981 augmente. Les deux premières courbes semblent indiquer quand à elles une rupture progressive dans les enjeux de la période post-1981, à partir de 2007-2012. La rupture semble d'un autre ordre que celle de 1981 ; elle est plus progressive.

4.4.4 Matrice récapitulative des erreurs

On encadre les périodes d'entraînement en noir et on fait apparaître toutes les erreurs obtenues lors des tests précédents.




FIGURE 4 – Matrice récapitulative

4.4.5 Conclusion partielle

Ainsi, cette tentative de valider les périodes de réalignements proposées par la science politique via des modèles d'apprentissage automatique semble nous permettre de conclure sur l'histoire récente. On observe effectivement un décrochage qui s'apparente à un changement profond des enjeux électoraux en 1981, et dans l'histoire plus récente, aux alentours de 2007. Notre analyse est imparfaite à certains égards : la fin du réalignement proposée par GOUYOU, 2024a est estimée à 2019 et il semble délicat de conclure avec des données n'allant que jusqu'à 2022. Rajouter dans la base de données les variables socio-économiques et les résultats des élections législatives de 2024 pourrait aider. Aussi, nous n'avons utilisé que les résultats des

élections législatives, quand les sources citées utilisaient toutes les élections à leur disposition : municipales, cantonales, européennes, législatives, présidentielles. Nous avons mis de côté nos tentatives d'utiliser plusieurs types d'élections en même temps puisque cela semblait plutôt dégrader nos résultats de prédiction. A l'époque où nous avons effectué ces tests, nous n'étions pas renseignés sur la théorie que nous étudions ici. Les mauvais résultats auraient aussi pu venir de la période d'entraînement choisie par exemple ; il me semble donc que creuser cette piste à la lumière des éléments apportés ici est intéressant. On se risquera à faire l'hypothèse que le caractère progressif du réalignement de 2007 est lié aux processus de fascisation de la société et des responsables politiques, bien plus progressifs que le tournant de la rigueur de Mitterrand par exemple, et avec des racines aussi anciennes que l'épisode du "bruit et l'odeur" de Jacques Chirac ou que la violence de la police ou les lois anti-immigration de Charles Pasqua dans les années 1990.

5 Etude des enjeux électoraux

5.1 Évolution des enjeux électoraux au cours du temps

Nous présentons ici les résultats de l’analyse par permutation importance conduite sur les différentes ères électorales définies en section 4. Les variables géographiques (`long`, `lat`) et temporelle (`annee`) ont été délibérément exclues de cette analyse afin de concentrer l’interprétation sur les seuls déterminants socio-économiques du vote à droite. Leur rôle spécifique fait l’objet d’une sous-section dédiée. Les ères retenues correspondent aux périodes électorales définies en section 4 à partir des élections législatives, ce qui restreint la fenêtre d’analyse à la Cinquième République.

Avertissement méthodologique préliminaire. Les performances globales du modèle (R^2 systématiquement négatifs, cf. Tableau 3) doivent être gardées à l’esprit lors de l’interprétation. Un R^2 négatif signifie que le modèle prédit moins bien que la moyenne empirique, ce qui implique que les importances par permutation doivent être lues avec prudence : elles indiquent quelles variables structurent le mieux les prédictions du modèle, mais non pas que ces prédictions soient bonnes en valeur absolue. La période ordinaire post-5^{ème} phase ($R^2 = -0.46$) est la seule où la dégradation reste modérée, ce qui en fait la fenêtre la plus fiable pour l’interprétation des importances.

TABLEAU 3 – Performance du modèle par ère électorale. R = Réalignement, O = Ordinaire, A = Ajustement.

Ère	Type	Année test	R^2	RMSE
4ème phase (Réalignement 1958–1962)	R	1969	−7.59	0.412
5ème phase (Réalignement 1981–1984)	R	1988	−4.01	0.163
Ajustement 1973–1974	A	1974	−519.53	0.423
Ajustement 1993–1995	A	1995	−1.06	0.109
Pré-réalignement 2012–2017	O	2017	−2.46	0.181
Période ordinaire post-5ème phase	O	2007	−0.46	0.071
Réalignement post-2017	R	2022	−2.54	0.166

Ce constat est lui-même un résultat : l’incapacité du modèle à prédire correctement le vote à droite sur la quasi-totalité des ères suggère que les variables socio-économiques disponibles sous-déterminent le vote lorsqu’on les considère isolément de la géographie et du temps. Cette observation est cohérente avec l’hypothèse formulée en section 4.1 et avec les travaux de GOUGOU (2024a), qui souligne le rôle central des enjeux symboliques et culturels — par définition absents du jeu de variables retenues.

La période ordinaire 1962–1981 : mobilité résidentielle et structure de classe

C’est sur cette ère que les importances par permutation atteignent leurs valeurs les plus élevées, et de loin : `popcommunes/percommu` (part de navetteurs) domine à 14,39, suivie par `popcommunes/peragglo` (part de la population résidant en agglomération) à 10,76, puis `cspcommunes/cadr_rank` (rang selon la part de cadres) à 7,57. Ces trois variables seules représentent l’essentiel du signal prédictif sur cette période (cf. Figure 5).

Ce résultat renvoie directement à la sociologie politique de la France des Trente Glorieuses. La période 1962–1981 est celle d’une urbanisation accélérée, d’un exode rural massif et de la constitution des grandes banlieues pavillonnaires et ouvrières. Le vote à droite est alors fortement corrélé à l’intégration dans les circuits économiques modernes : les communes à forte proportion de cadres et de navetteurs vers les pôles urbains penchent à droite, tandis que la France rurale traditionnelle et la France ouvrière constituent les bastions de la gauche. La *percommu* est ici un proxy de la modernisation économique au sens large : une commune où beaucoup d’habitants font la navette quotidiennement est une commune intégrée dans le marché du travail urbain-industriel, structurellement différente des communes agricoles isolées.

La forte importance de `pibtot` (4,98) et de la structure démographique brute (`popf`, `popph`) s’inscrit dans la même logique : le PIB total communal et la taille de la population sont des marqueurs de l’armature urbaine et donc de la géographie du vote dans la France gaulliste et pompidolienne.

À noter que l’importance très négative de `pibtot_pctchange` (environ -6.5 , visible

sur la Figure 6) traduit un phénomène différent : permuter la variable *croissance* du PIB améliore les prédictions, ce qui signifie que le modèle a appris une relation inversée entre cette variable et le vote — plausible dans une période où les gains de productivité étaient diffus et ne structuraient pas encore le vote comme aujourd’hui.

Le réalignement de 1981 : effondrement du signal socio-économique

La 5^{ème} phase de réalignement (test sur 1988) est caractérisée par un basculement net : les importances deviennent massivement négatives, notamment `capitalimmobiliercommunes/capitalrat` (-0.61) et `cspcommunes/cadr_rank` (-0.28). Ce résultat est cohérent avec la rupture identifiée en section 4.4.2 : un modèle entraîné sur la période 1965–1981 prédit à rebours le vote de 1988.

Ce renversement des importances a une signification politique précise. Comme le documentent (GOUGOU, 2024a ; GOUGOU & MARTIN, 2013 ; LABOURET, 2014 ; MARTIN, 2000), la période 1981–1984 est celle de l’effondrement du Parti communiste, de l’émergence du Front national et du basculement du Parti radical vers la droite. Ces recompositions brisent la corrélation entre appartenance de classe supérieure et vote à droite qui structurait la période précédente : une part de l’électorat ouvrier et de la petite classe moyenne, jusque-là ancrée dans la gauche traditionnelle ou abstentionniste, commence à se déplacer vers l’extrême droite. Dans ce contexte, les variables socio-économiques qui prédisaient correctement le vote à droite avant 1981 deviennent contre-prédictives après, reflétant le fait que les déterminants du vote ont structurellement changé.

La chute brutale de l’importance du capital immobilier est particulièrement significative. Dans la France des Trente Glorieuses, la propriété immobilière était un marqueur fort du vote de droite modérée ; après 1981, avec la montée en puissance des enjeux d’insécurité et d’immigration identifiés par MARTIN (2000) comme centraux dans le réalignement, le clivage patrimonial perd de sa valeur prédictive autonome.

La période ordinaire post-5^{ème} phase (1988–2007) : stabilisation autour de la mobilité

C’est sur cette ère que le modèle obtient ses moins mauvaises performances ($R^2 = -0.46$), ce qui rend les importances comparativement plus fiables. On observe un retour à des importances positives, mais d’un ordre de grandeur très inférieur à la période 1962–1981 : `percommu` reste la variable la plus importante (0.105), suivie des variables de population brute (0.046–0.056).

L’érosion de l’importance absolue des variables socio-économiques traduit une complexification du paysage électoral : les alternances RPR/PS, les cohabitations et le maintien d’une extrême droite électoralement forte mais isolée créent un vote moins lisible depuis les seules caractéristiques communales. Le vote à droite n’est plus concentré dans une géographie socio-économique aussi nette qu’en 1962–1981 ; il commence à se diffuser dans des milieux plus hétérogènes, notamment sous l’effet de la stratégie de droitisation sarkozyste évoquée en section 4.4.2.

L’importance quasi nulle du diplôme (`suph_rank`, `supf_rank`) sur cette période est notable. Elle confirme que le clivage éducatif, aujourd’hui central dans la sociologie électorale française (GOUGOU, 2024a), n’était pas encore structurant pour le vote à droite dans la période 1988–2007 : le Parti socialiste et le RPR se partageaient alors des électorats aux niveaux d’instruction non encore différenciés de façon aussi marquée qu’après 2017.

Le pré-réalignment 2012–2017 : brouillage des signaux

La période 2012–2017 présente des importances légèrement négatives pour la majorité des features, avec `agesexcommunes/poph` (−0.127) et `agesexcommunes/popf` (−0.102) en tête. Ces valeurs négatives sur des variables de population brute sont difficiles à interpréter comme un signal positif ; elles reflètent plutôt l’instabilité prédictive caractéristique d’une période de transition.

Ce résultat est cohérent avec le constat de la section 4.4.3 : l’ordre électoral issu des années 1980 commence à se défaire progressivement. La montée de Marine Le Pen, la crise du

bipartisme traditionnel et l'émergence de nouveaux clivages autour de la mondialisation et de l'identité créent une période de brouillage où les variables socio-économiques disponibles ne suffisent plus à cartographier le vote à droite.

Le réalignement post-2017 : l'émergence du signal éducatif

La comparaison avec les ères précédentes révèle ce qui constitue selon nous le résultat le plus saillant de cette analyse : l'importance des variables de diplôme du supérieur augmente de façon nette et cohérente depuis la période ordinaire post-5^{ème} phase jusqu'au réalignement post-2017 (cf. Figure 6). `diplomescommunes/suph_rank` atteint 0.169 et `diplomescommunes/supf_rank` 0.145 pour le réalignement post-2017, faisant des diplômes du supérieur les premières variables socio-économiques prédictives du vote à droite sur cette période.

Ce résultat valide quantitativement la thèse centrale de GOUGOU (2024a) : l'élection de 2022 confirme la consolidation d'un nouvel ordre électoral structuré autour du clivage éducatif, les communes à forte proportion de diplômés du supérieur votant désormais massivement pour les partis de centre-gauche et de gauche (La France Insoumise, PS) tandis que les communes à faible niveau d'instruction penchent vers le Rassemblement National et, dans une moindre mesure, vers les partis de droite modérée (LR). Le fait que `suph_rank` domine légèrement `supf_rank` (0.169 contre 0.145) pourrait refléter la sur-représentation masculine dans les catégories de diplômés du supérieur les plus anciennement constituées.

La montée conjointe de `cspcommunes/cadr_rank`, qui retrouve une importance positive dans cette période, est cohérente : dans le nouveau paysage politique post-2017, la part de cadres est fortement corrélée avec le niveau de diplôme et la localisation métropolitaine, deux facteurs structurant le vote pro-Macron ou pro-gauche.




FIGURE 5 — Importance par permutation (top 10 features) par ère électorale. Les valeurs négatives indiquent qu’une variable nuit aux prédictions du modèle sur cette ère ; les valeurs positives élevées signalent les déterminants socio-économiques dominants. Variables géographiques et temporelles exclues.




FIGURE 6 — Évolution de l’importance par permutation des principales features socio-économiques à travers les ères électorales. Les fonds colorés indiquent le type d’ère : rouge = réalignment, vert = politique ordinaire, orange = ajustement. La chute brutale de *cadr_rank* après le réalignment de 1981 et la montée du diplôme après 2017 constituent les deux ruptures majeures identifiées.

Synthèse : trois régimes de déterminants socio-économiques

L'ensemble de ces observations permet de distinguer trois régimes distincts dans la relation entre variables socio-économiques et vote à droite en France depuis 1965 :

1. **Le régime de classe (1962–1981).** Le vote à droite est fortement prédit par la structure de classe et l'intégration dans l'économie urbaine : mobilité résidentielle, part de cadres, taille de l'agglomération. C'est le vote de la France modernisée des Trente Glorieuses, en opposition à la France ouvrière et agricole.
2. **Le régime de brouillage (1981–2012).** Les réalignements successifs et la montée de l'extrême droite dissolvent progressivement la lisibilité socio-économique du vote à droite. Aucune variable ne domine clairement, les importances sont faibles ou négatives, le modèle échoue à généraliser.
3. **Le régime éducatif (2017–présent).** Le clivage éducatif émerge comme le principal déterminant socio-économique mesurable du vote, avec une importance croissante du diplôme du supérieur. Ce régime est cohérent avec la recomposition du paysage politique autour d'un axe ouvert/fermé ou métropole/périphérie documenté par la sociologie électorale contemporaine (GOUGOU, [2024a](#) ; GOUGOU & MARTIN, [2013](#)).

La transition entre ces trois régimes n'est pas instantanée : elle est progressive entre 1981 et 2017, comme le suggère l'analyse de la section 4.4.3, et reflète l'accumulation lente de transformations sociales — désindustrialisation, expansion de l'enseignement supérieur, montée des enjeux culturels — dont les effets électoraux ne se cristallisent qu'à partir du réalignement de 2017.

5.2 Rôle des variables géographiques et temporelles

La variable année : apprentissage par proximité temporelle

L'inclusion de l'année électorale comme variable explicative introduit dans le modèle une forme de *pondération temporelle implicite*. En présence de `annee`, la forêt aléatoire ap-

prend à s'appuyer davantage sur les élections les plus proches de l'année de test : les patterns socio-économiques récents sont ainsi surpondérés par rapport aux élections lointaines. Concrètement, un modèle entraîné sur 1988–2017 et testé sur 2022 accordera, lorsque `annee` est présente, une importance accrue aux observations de 2017, plus proches structurellement de 2022 que de celles de 1988.

Ce mécanisme améliore les performances de prédiction à court terme puisqu'il revient à filtrer implicitement le signal historique selon sa pertinence temporelle. En contrepartie, il réduit l'interprétabilité des importances par permutation pour les autres variables : une partie du signal attribué à une feature socio-économique peut en réalité provenir de sa corrélation avec la tendance temporelle capturée par `annee`. C'est pour cette raison que les analyses de la sous-section précédente ont exclu `annee` afin d'isoler les effets socio-économiques purs.

Protocole expérimental

L'impact des coordonnées géographiques (`long`, `lat`) est mesuré à trois niveaux complémentaires, sur les quatre fenêtres temporelles du benchmark de réalignement introduites en section 4 : entraînement sur 1988–2007 (test 2012), 1988–2012 (test 2017), 1988–2017 (test 2022) et 2007–2017 (test 2022).

Performance globale. Pour chacune de ces quatre fenêtres, deux modèles sont entraînés à conditions égales : l'un conserve `long` et `lat`, l'autre les supprime. Le gain de R^2 attribuable à la géographie est mesuré par $\Delta R^2 = R^2_{\text{avec}} - R^2_{\text{sans}}$.

Transfert d'importance. Sur la fenêtre de référence (entraînement 1988–2017, test 2022), on compare les importances par permutation des features socio-économiques avec et sans géographie. Un $\Delta \text{PI} > 0$ indique qu'une variable gagne de l'importance en l'absence de coordonnées : elle compense partiellement la perte d'information géographique et révèle ainsi ce que la géographie proxifiait.

Variation par ère. L'expérience est reproduite pour chaque ère électorale définie en section 4 afin de vérifier si la contribution géographique est stable au cours du temps ou si elle

varie selon les régimes électoraux. Ces ères couvrent une fenêtre plus large que les quatre fenêtres du benchmark, ce qui explique que les tableaux de cette sous-section comportent davantage de lignes.

Résultats : impact sur la performance

TABLEAU 4 – Impact des coordonnées géographiques sur les métriques de performance. $\Delta R^2 > 0$: la géographie améliore les prédictions ; $\Delta R^2 < 0$: la géographie dégrade les prédictions.

Fenêtre	Test	R^2 (avec)	R^2 (sans)	ΔR^2	MAE (avec)	MAE (sans)
1988–2007	2012	−0.727	−1.197	+0.470	0.079	0.088
1988–2012	2017	−2.656	−2.569	−0.087	0.166	0.160
1988–2017	2022	−2.145	−2.454	+0.309	0.157	0.159
2007–2017	2022	−0.637	−0.316	−0.321	0.106	0.090

Les résultats du Tableau 4 révèlent un impact **non monotone** de la géographie, ce qui constitue le premier résultat saillant de cette analyse. Deux expériences bénéficient de la géographie ($\Delta R^2 = +0.47$ et $+0.31$) et deux en pâtissent ($\Delta R^2 = -0.09$ et -0.32).

L’opposition la plus instructive est celle des deux expériences testées sur 2022 : lorsque le modèle est entraîné sur la longue fenêtre 1988–2017, la géographie aide ($+0.31$) ; lorsqu’il est entraîné sur la fenêtre courte 2007–2017, elle nuit fortement (-0.32). Ce résultat suggère que les coordonnées géographiques sont utiles pour capter des régularités de *long terme* dans la distribution spatiale du vote, mais qu’elles introduisent du bruit lorsque le modèle est entraîné sur des élections récentes : dans ce cas, les structures géographiques héritées du passé deviennent des faux signaux qui contredisent les dynamiques contemporaines du vote.

Le cas du test sur 2017 ($\Delta R^2 = -0.09$) s’inscrit dans la même logique : 2017 est précisément l’élection de rupture où la carte électorale se reconfigure (effondrement de la géographie PS vs RPR au profit d’un nouveau clivage métropole/périphérie). Les coordonnées géographiques, entraînées sur l’ancien ordre électoral, deviennent contre-productives face à cette reconfiguration.

Résultats : ce que la géographie proxifie




FIGURE 7 — Gauche : R^2 avec et sans coordonnées géographiques par fenêtre temporelle. Centre : contribution nette de la géographie (ΔR^2), rouge si > 0.10 , vert si ≤ 0.05 . Droite : transfert d’importance vers les features socio-économiques lors du retrait de la géographie (test 2022, fenêtre 1988–2017).

Le subplot droit de la Figure 7 révèle quelles variables socio-économiques absorbent le signal géographique lorsque `long` et `lat` sont supprimées (test 2022, fenêtre 1988–2017). Les trois plus grands gagnants sont :

- `diplomescommunes/supf_rank` ($\Delta\text{PI} = +0.246$) : rang selon la part de femmes diplômées du supérieur.
- `popcommuneselecteurs/electeurs_rank` ($\Delta\text{PI} = +0.185$) : rang selon le nombre d’électeurs inscrits.
- `diplomescommunes/suph_rank` ($\Delta\text{PI} = +0.122$) : rang selon la part d’hommes diplômés du supérieur.

Ce résultat est interprétable directement : les coordonnées géographiques proxifient en grande partie la **ségrégation éducative spatiale**. En France post-2017, les diplômés du supérieur se concentrent massivement dans les métropoles et les grandes villes universitaires — Paris, Lyon, Bordeaux, Rennes, Montpellier — qui sont aussi des zones géographiquement identifiables par leurs coordonnées. Lorsque la géographie est retirée, le modèle doit reconstruire cette information à partir de ses proxys socio-économiques directs : c’est le diplôme qui prend le relais.

La montée de `electeurs_rank` (+0.185) est également cohérente : le nombre d’électeurs inscrits est un proxy de la taille de la commune et donc de son caractère urbain ou rural, information que la géographie portait directement via les coordonnées.

À l’inverse, deux variables de capital immobilier perdent de l’importance lorsqu’on retire la géographie : `capitalratio_pctchange` ($\Delta\text{PI} = -0.094$) et `capitalratioagglo_pctchange` ($\Delta\text{PI} = -0.118$). Ces variables mesuraient des dynamiques immobilières locales dont la pertinence prédictive était amplifiée par leur ancrage géographique : la variation du ratio capital immobilier dans une commune prend son sens en relation avec son bassin économique régional, information que `long` et `lat` structuraient implicitement.

Résultats : variation par ère

TABLEAU 5 – Impact de la géographie par ère électorale. $\Delta R^2 > 0$: géographie bénéfique ; $\Delta R^2 < 0$: géographie contre-productive. Les valeurs extrêmes pour 1974 reflètent la qualité dégradée des données sur cette période et non un effet géographique réel ; les ΔR^2 correspondants sont non interprétables.

Ère	Type	Test	R^2 (avec)	R^2 (sans)	ΔR^2
4ème phase (Réalignement 1958–1962)	R	1969	−7.664	−7.590	−0.074
Ajustement 1973–1974	A	1974	−524.8	−519.5	<i>n.i.</i>
5ème phase (Réalignement 1981–1984)	R	1988	−3.836	−4.608	+0.772
Ajustement 1993–1995	A	1995	−0.950	−1.063	+0.113
Période ordinaire post-5ème phase	O	2007	−0.194	−0.462	+0.268
Pré-réalignement 2012–2017	O	2017	−2.240	−2.460	+0.220
Réalignement post-2017	R	2022	−2.676	−2.544	−0.132

Les résultats par ère (Tableau 5) dessinent un schéma temporel clair. La géographie est **bénéfrique de 1988 à 2017** (ΔR^2 positifs sur cinq ères consécutives) et **contre-productive aux extrémités** de la fenêtre analysée : avant 1988 et après 2017.

La contre-productivité avant 1988 est probablement de nature technique : les données socio-économiques disponibles pour les années 1960–1970 sont de qualité insuffisante pour

alimenter un modèle cohérent. Les R^2 catastrophiques de -524 pour 1974 signalent une défaillance des données plutôt qu’un signal géographique.

La contre-productivité *après* 2017 en revanche est substantielle et interprétable ($\Delta R^2 = -0.132$). Elle confirme l’hypothèse déjà formulée : le réalignement post-2017 reconfigure la géographie électorale selon de nouveaux axes (métropoles vs périphérie, centres-villes diplômés vs zones rurales et périurbaines peu diplômées) qui ne correspondent plus aux structures géographiques héritées des décennies précédentes. Les coordonnées `long/lat` apprises sur les élections 1988–2017 deviennent ainsi des faux signaux pour prédire 2022, tandis que les features socio-économiques — notamment le diplôme — capturent mieux cette nouvelle structure.

Synthèse

La géographie joue un rôle de **proxy de la ségrégation spatiale** des caractéristiques socio-économiques : elle encode dans un format compact l’information sur la localisation urbaine, la densité éducative et la structure du marché immobilier local. Son utilité prédictive est maximale lorsque cette ségrégation est stable — ce qui est le cas de la période 1988–2017, caractérisée par des géographies électorales relativement persistantes. Elle devient un handicap lorsque la reconfiguration électorale est en cours ou achevée, comme c’est le cas du réalignement post-2017 : les coordonnées retiennent alors la mémoire d’un ordre géographique révolu.

Ce résultat a une implication méthodologique directe : pour un modèle de *prédiction* à court terme (prédire la prochaine élection), la géographie est utile si l’ordre électoral est stable, et nuisible en période de transition. Pour une analyse *interprétative* des déterminants du vote, son retrait révèle les véritables variables structurantes — en l’occurrence, le diplôme du supérieur, qui capte à lui seul une fraction substantielle de la variance géographique du vote dans la France contemporaine.

5.3 Enjeux locaux du vote d’extrême droite

Nous nous sommes finalement intéressés à la dynamique de vote pour la droite conservatrice et l’extrême droite dans l’ère électorale la plus récente (2007 à 2022), qui est un sujet particulièrement étudié dans le climat politique actuel, tant par les sociologues que par les partis (notamment de gauche) pour des questions électorales. En effet, et en accord avec l’observation de la section précédente, la progression de l’extrême droite se fait principalement dans la classe moyenne rurale peu diplômée qui aurait selon PIKETTY et CAGÉ, 2023 subi - ou a peur de subir - un déclassement social avec la mondialisation et la reconfiguration de l’économie française. Mais comment caractériser ce déclassement ? On pense d’abord à chercher un éventuel lien entre l’évolution du vote classé extrême droite (ED) par le ministère de l’Intérieur, et celles de différentes variables socio-économiques à l’échelle de la commune comme le PIB, le taux de chômage, la proportion de propriétaires, ou encore le prix de l’immobilier : le déclassement renvoyant à un recul de pouvoir d’achat et de statut social, ces variables liées au chômage et à la capacité de devenir propriétaire sont les proxys les plus prometteurs à notre disposition. Le lecteur attentif notera l’ommission volontaire des features liées au niveau de diplôme pour se concentrer sur l’effet du déclassement purement économique.

Toutefois, comme nous l’avons montré dans la section précédente, observer ces données sur toutes les communes de France et sur plusieurs années nous fournit hélas peu d’informations. Un coup d’œil à la carte de France en 2022 en figure 8 permet de saisir la forte dépendance spatiale du vote ED, notamment dans les bastions historiques : le Nord, le Grand-Est et la région Provence-Alpes-Côte d’Azur (PACA). Ce constat rejoint directement les conclusions de la section 5.2 : la géographie capte ici des spécificités locales divergentes entre régions, dont les déterminants socio-économiques sous-jacents font l’objet de la présente sous-section.

5.3.1 Un peu de contexte sociologique

Afin d’affiner notre étude numérique, tournons-nous une fois de plus du côté de la sociologie. Dans leurs livres, COQUARD, 2019 et FAURY, 2024 détaillent leurs études de terrain auprès d’électeurs d’ED sur plusieurs années, respectivement dans les régions Grand




FIGURE 8 – Visualisation des communes de France en fonction du pourcentage de vote ED et du nombre d’inscrits en 2022

Est et PACA. Si de nombreux thèmes socio-économiques sont communs aux deux études (pression sociale anti-chômage, faible niveau d’études, valorisation du statut de propriétaire et d’entrepreneur), les spécificités locales sont mises en avant par les deux sociologues. Le Nord et le Grand Est sont en déclin économique suite à la désindustrialisation et font face à un fort taux de chômage. À l’inverse, la région PACA est extrêmement dynamique économiquement ; toutefois les classes moyennes électriques de l’ED se sentent pressurées par le bas par une forte immigration économique (les immigrés étant perçus, à tort, comme n’ayant en majorité pas d’activité et touchant des aides) et par le haut par une immigration de classes supérieures domestiques et étrangères qui font monter drastiquement les prix de l’immobilier, notamment sur le littoral provençal.

5.3.2 Méthodologie du test

Nous restreignons désormais notre étude aux régions Nord, Grand Est et PACA. Les données sont agrégées par département comme décrit en section 3.2, et pré-filtrées en sélectionnant une trentaine de features pertinentes à la validation quantitative des observations de B. Coquard et F. Faury (proportion de chômage, prix de l’immobilier, proportion de propriétaires, entre autres), sur la période 2007–2022, couvrant les études des deux sociologues. Un régresseur Random Forest à 100 estimateurs est entraîné pour chaque région avec la proportion de vote ED aux législatives en variable expliquée.

La permutation importance (PI) est ensuite calculée de deux façons : soit sur les données de la même région qu'à l'entraînement (évaluation intra-régionale), soit sur les données d'une autre région (évaluation inter-régionale, le Grand Est servant de référence). Une feature correspondant au numéro du département est conservée en tant que *dummy* : étant indépendante de la proportion de vote ED par construction, elle sert de référence de bruit ; toute feature dont la PI en valeur absolue est inférieure à celle de la *dummy* est considérée comme non significative.

À noter que l'évaluation intra-régionale utilise les mêmes données à l'entraînement et au test ; les scores PI obtenus peuvent donc surestimer l'importance réelle des features en raison du risque de surapprentissage, et doivent être interprétés avec cette réserve.

5.3.3 Résultats

Dans un premier temps, nous évaluons les 3 régions de manière intra-régionale afin de déceler quantitativement les principaux déterminants du vote ED dans chacune d'elles. Les résultats sont présentés dans les tables 6, 7 et 8. Seules les features ayant une PI supérieure à celle de la variable *dummy* sont conservées. On notera var% la feature dérivée de la variation en pourcentage d'une feature par rapport à sa valeur à l'élection précédente.

Feature	PI
ratio PIB (var%)	0.34
latitude	0.18
percentile capital immo (var%)	0.08
ratio capital immo (var%)	0.07
ratio PIB	0.06
(dummy)	0.05

TABLEAU 6 – PI sur la région Grand Est

Feature	PI
ratio PIB	0.41
ratio revenus	0.26
percentile revenus	0.15
ratio PIB (var%)	0.07
proportion chômeurs	0.07
percentile capital immo (var%)	0.06
longitude	0.05
ratio capital immobilier (var%)	0.04
prix immobilier	0.03
ratio revenus (var%)	0.02
latitude	0.01
(dummy)	0.01

TABLEAU 7 – PI sur la région Nord

Feature	PI
proportion chômeurs	0.12
(dummy)	0.11

TABLEAU 8 – PI sur la région PACA

Dans un deuxième temps, nous nous sommes intéressés à l'évaluation inter-régionale du Nord et de la région PACA (le Grand Est en référence) afin de déceler des déterminants communs (PI élevée et positive) ou contraires (PI négative et grande valeur absolue). Les résultats sont présentés dans les tables 9 et 10. Comme précédemment, pour la région Nord seules les features dont la PI est supérieure en valeur absolue à celle du dummy sont gardées, et pour la région PACA seules les features dont la PI est supérieure à 0.01 en valeur absolue (car la variable dummy a une PI de 0 sur cette configuration).

Feature	PI
ratio PIB	0.14
(dummy)	0.10

TABLEAU 9 – PI sur la région Nord, modèle entraîné sur le Grand Est

Feature	PI
ratio PIB (var%)	-0.25
percentile capital immo (var%)	-0.09
ratio capital immobilier (var%)	-0.09
prix immobilier (var%)	-0.05
proportion chômeurs	-0.04
ratio PIB	-0.02
percentile revenus (var%)	-0.02
percentile capital immo	-0.01
ratio revenus (var%)	0.01

TABLEAU 10 – PI sur la région PACA, modèle entraîné sur le Grand Est

5.3.4 Discussion

Pour les régions Nord et Grand Est, l’analyse par PI semble confirmer les observations issues de la sociologie. En table 6, la feature avec la PI la plus grande (de loin) est l’évolution du ratio PIB de la commune sur PIB moyen national. Cela caractérise l’hypothèse d’un renforcement du vote ED dû au déclin économique relatif de la région. Pour la région Nord (table 7), c’est cette fois le ratio du PIB et des revenus, ainsi que le percentile moyen de revenus par rapport au niveau national (valeurs brutes) qui ressortent largement, suivies par les indicateurs du chômage et du capital immobilier : encore une fois la précarité économique de la région est le principal déterminant du vote ED dans notre sous-ensemble de features. Il est difficile d’interpréter le résultat de la région PACA en table 8 : la seule feature avec une PI supérieure à celle de la dummy, la proportion de chômeurs, présente un score très similaire à cette dernière, ce qui ne permet pas de conclure à un effet significatif. D’après les observations de terrain, nous pouvions nous attendre à une prépondérance des features liées au capital immobilier pour caractériser la gentrification de la région ; nous ne retrouvons pas cette observation dans l’analyse par PI, ce qui peut s’expliquer en partie par la limite méthodologique évoquée plus haut.

Pour l’analyse comparée Nord - Grand Est, la seule variable sélectionnée présente un score très proche du dummy. Cependant cette variable (le ratio du PIB) correspond à l’analyse sociologique et aux analyses par PI individuelles des deux régions. Enfin, l’analyse comparée entre la région PACA et le Grand Est, notamment par l’importante PI négative de l’évolution

du ratio du PIB, corrobore la divergence du contexte économique entre ces deux régions : une même feature peut influencer positivement le vote ED dans ses deux sens de variation selon le contexte géographique. On retrouve également les features du capital immobilier avec une PI négative, indiquant qu’une augmentation des prix et une concentration du capital immobilier est associée à une hausse du vote ED en PACA, à l’inverse de ce que l’on observe dans le Grand Est.

En conclusion, les observations de terrain de B. Coquard et F. Faury sont en partie confirmées par les données à l’échelle départementale. Ces spécificités locales divergentes éclairent par ailleurs les résultats de la section 5.2 : la prépondérance des features géographiques (longitude et latitude) dans l’analyse par PI à l’échelle nationale s’explique précisément par le fait que la géographie encode des dynamiques socio-économiques régionalement contrastées, dont les effets s’annulent ou se masquent mutuellement lorsqu’on les agrège sur l’ensemble du territoire.

6 Conclusion

Ainsi, durant ce projet, nous avons pu tester quantitativement des théories provenant de la science politique et de la sociologie, avec des méthodes modernes de science des données.

D’abord, nous avons tenté de valider des périodes de réalignements récentes proposées par la science politique. On observe effectivement un décrochage qui s’apparente à un changement profond des enjeux électoraux en 1981, et dans l’histoire plus récente, aux alentours de 2007.

Ensuite, nous avons analysé les enjeux du vote au cours du temps, pour en tirer trois régimes. De 1962 à 1981 c’est un vote de classe qui domine ; puis jusqu’en 2007-2012, l’analyse est plutôt infructueuse et ne fait ressortir aucune variable socio-économique particulière, avant de révéler un vote largement expliqué par le niveau de diplôme depuis 2017. Nous avons aussi analysé le fait que la prépondérance des features géographiques (longitude et latitude) à l’échelle nationale s’explique par le fait que la géographie encode des dynamiques socio-économiques régionalement contrastées, dont les effets s’annulent ou se masquent mutuellement lorsqu’on les agrège sur l’ensemble du territoire.

Enfin, nous avons travaillé sur les déterminants du vote à l’extrême droite dans les régions Nord, Grand Est et PACA et confirmé les analyses des sociologues Benoît Coquard et Félicien Faury. Pour les régions Nord et Grand Est, l’analyse semble confirmer l’hypothèse d’un renforcement du vote ED dû au déclin économique relatif de la région. Malgré des limites méthodologiques dans l’analyse de la région PACA, on obtient tout de même que l’augmentation des prix et la concentration du capital immobilier y favorisent un vote extrême-droite. Cette comparaison souligne ainsi deux logiques territoriales opposées : une réaction au déclin économique dans le Nord-Est face à une dynamique d’accumulation et d’exclusion foncière dans le Sud-Est.

Références

- ALESSIO, M. (2026). Simulateur élections municipales. <https://municipales.streetpress.com/page/la-methodologie>
- COQUARD, B. (2019). Ceux qui restent. *Esprit*, (11), 97-102.
- DATAGOUV. (2026). Données des élections agrégées. <https://www.data.gouv.fr/datasets/donnees-des-elections-agregees>
- FAURY, F. (2024). *Des électeurs ordinaires : enquête sur la normalisation de l'extrême droite*. Seuil.
- GOUGOU, F. (2024a). La consolidation d'un nouvel ordre électoral ? : Les élections françaises de 2022 dans la perspective des réalignements. *Revue française de science politique*, Vol. 72(6), 915-943. <https://doi.org/10.3917/rfsp.726.0915>
- GOUGOU, F. (2024b). Une autre histoire du conflit politique. Autour du livre de J. Cagé et T. Piketty. *Analyse Opinion Critique*.
- GOUGOU, F., & MARTIN, P. (2013). L'émergence d'un nouvel ordre électoral ? [Section : Science politique]. In *Des votes et des voix. De Mitterrand à Hollande* (p. 121-132). Champ social. <https://doi.org/10.3917/chaso.tiber.2013.01.0121>
- LABOURET, S. (2014, décembre). *La rupture de 2007 : changement électoral et dynamiques de réalignement en France* [Theses]. Université de Grenoble [Issue : 2014GRENH038]. Consulté le 7 décembre 2025 à <https://theses.hal.science/tel-01348266>
- LESUEUR, C. (2024). Elections européennes 2024 : le RN s'implante dans la quasi-totalité de la France. *Le Monde*. https://www.lemonde.fr/politique/article/2024/06/11/elections-europeennes-le-rassemblement-national-s-implante-sur-la-quasi-totalite-du-territoire_6238669_823448.html
- MARTIN, P. (2000). *Comprendre les évolutions électorales. La théorie des réalignements revisitée*. Presses de Sciences Po.
- PIKETTY, T., & CAGÉ, J. (2023). *Une histoire du conflit politique : élections et inégalités sociales en France, 1789-2022*. Seuil.