

Analyse et Modélisation des Élections en France

Résumé (original 44 pages) — Projet SDI 3^e année, Centrale Supélec / Univ. Paris-Saclay, 2025–2026

Encadrant : Damien Challet Membres : Lucas Lacampagne, Khelil Tabanne, Yann Chauvard

Contexte et Motivations

Ce projet se situe à l’intersection de la science politique et de la science des données. Profitant du développement récent des méthodes d’apprentissage automatique, nous souhaitons tester *quantitativement* des théories issues de la sociologie et de la science politique, en mobilisant des données électorales et socio-économiques sur près d’un siècle. L’entrée dans ce projet s’est faite par un constat empirique : la prédiction du vote à l’échelle communale donne de très mauvais résultats dès lors que l’on sort de la période d’entraînement — suggérant une *non-stationnarité* des enjeux électoraux que la littérature en science politique formalise sous le nom de théorie des réalignements [4, 3].

Trois questions structurent notre démarche :

- (1) Les variables socio-économiques communales **sous-déterminent-elles** le vote ? Les déterminants du vote extrême droite (ED) (sentiment d’insécurité, perceptions migratoires) n’ont pas de mesure objective dans les bases administratives. Quel est le plafond prédictif des seules données matérielles ?
- (2) Les **enjeux électoraux sont-ils stationnaires** ? La théorie des réalignements distingue des périodes de *politique ordinaire* (enjeux stables) et des *réalignements* (reconfiguration durable du paysage partisan). Un modèle entraîné sur une période ordinaire doit, selon cette théorie, échouer à prédire les élections hors de cette période.
- (3) Les **déterminants locaux** du vote sont-ils homogènes ? Des enquêtes de terrain dans le Grand Est [1] et en PACA [2] sur le vote ED suggèrent des logiques régionales opposées, que nous cherchons à confirmer avec des données départementales.

Données

Base électorale et socio-économique principale

T. Piketty et J. Cagé [5] ont agrégé à l’échelle **communale** des résultats électoraux depuis le XIX^e siècle (législatives, présidentielles, référendums) et des centaines d’indicateurs socio-économiques administratifs : revenus, PIB, capital immobilier, structure démographique, diplômes, catégories socio professionnelles (CSP), mobilité résidentielle, parc de logements. Les résultats sont classés en blocs politiques par le ministère de l’Intérieur (G, CG, C, CD, D, ED).

Nous complétons cette base par les résultats des **élections européennes 1999–2024** agrégés au niveau communal. Ces données, absentes de la base initiale, ont été construites par nos soins via les fichiers bruts de DataGouv et une classification politique manuelle (listes régionalistes, animalistes, souverainistes). La motivation est double : enrichir les séries temporelles très courtes (à partir de 1981, les législatives ne fournissent que 9 points par commune) et exploiter la capacité des européennes à anticiper les dynamiques électorales nationales — confirmée récemment

par la percée du Rassemblement National (RN) en 2024. Toutefois nous n’avons utilisé que les élections législatives dans la suite.

Sélection des variables (pipeline MI–VIF)

À partir de plusieurs centaines d’indicateurs bruts, un pipeline en deux étapes est appliqué :

- **Information mutuelle** (estimateur de Kraskov, **scikit-learn**) : mesure la dépendance statistique sans hypothèse de linéarité, particulièrement adaptée aux effets de seuil fréquents en sociologie électorale : $I(X_j; y) = \iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy$. Les $n = 50$ variables au score le plus élevé sont conservées.
- **VIF itératif** (< 10) : élimination des variables redondantes pour stabiliser les estimateurs et les importances : $VIF_j = 1/(1 - R_j^2)$.

19 variables sont retenues : PIB (total, variation, delta), capital immobilier (stock, ratio, variation agglomération), nombre de logements, rangs selon la part de diplômés supérieurs (hommes, femmes), rang de la part de cadres, rang selon la part d’agriculteurs, populations féminine et masculine, part en agglomération, part de navetteurs, rang du nombre d’électeurs, latitude et longitude.

Méthodes

Forêt aléatoire et forêt oblique

Le modèle de base est une **forêt aléatoire** : $\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x)$, entraînée par bagging avec sélection aléatoire des variables à chaque nœud (séparations axiales). Une **forêt oblique** (séparations $\mathbf{a}^\top x \leq \tau$ selon des combinaisons linéaires) a été testée pour capturer des frontières non orthogonales — pertinentes si l’effet d’un fort taux de diplômés dépend conjointement de la densité de cadres et du capital immobilier. Les performances étant comparables (R^2 et RMSE quasi-identiques), la forêt standard a été retenue pour sa robustesse aux valeurs manquantes dans les données communales historiques.

Validation croisée temporelle (ElectionYearCV)

La validation croisée standard crée une fuite temporelle : des communes d’une même année se retrouvent dans les deux plis, laissant filtrer de l’information future vers l’entraînement. Notre découpeur personnalisé génère des plis glissants sur des *années électorales entières* : $\text{Train}[e_1, \dots, e_{k-1}] \rightarrow \text{Val } e_k$. La variable **annee** est transmise via **groups** dans **GridSearchCV** (scikit-learn) et exclue des features explicatives. Hyperparamètres optimaux sur 1988–2017 : **max_depth=None**, **min_samples_leaf=10**, **n_estimators=200**.

Permutation importance (PI)

La contribution de chaque variable est mesurée par la dégradation de la RMSE (ou du R^2) lorsque ses valeurs sont permutées aléatoirement sur l’ensemble de test. Contrairement à l’impureté de Gini, la PI est indépendante de la

structure interne des arbres et directement interprétable.

Architecture logicielle

Un pipeline complet a été développé : **DataHandler** (chargement Parquet par predicate pushdown, séparation temporelle stricte, agrégation départementale pondérée par la population), **RegressorWrapper** (encapsulation unifiée compatible scikit-learn, optimisation des hyperparamètres, calcul de la PI), **ElectionYearCV** (découpeur personnalisé). Le code source du projet peut être consulté à [ce lien](#).

Résultats

Validation des réalignements électoraux




FIGURE 1 – Courbes RMSE (vote à gauche) par année électorale, 4 fenêtres d’entraînement en 1962–1981. Fond jaune = entraînement, gris = réalignement supposé, blanc = politique ordinaire supposée. La RMSE est systématiquement minimale sur les élections de la même période.




FIGURE 2 – Courbes RMSE (vote à droite), fenêtres 1984–2007. Rupture 1981 : RMSE chute de $\sim 0,27$ (1978) à $\sim 0,05$ (1981) sur la courbe rouge. “Mur électoral” de 1981 visible ; remontée progressive à partir de 2007–2012.

L’erreur RMSE est minimale ($\approx 0,05$ – $0,09$) sur les élections de la même période ordinaire que l’entraînement, et double voire triple lors des réalignements. Deux ruptures majeures :

- **1981** : (Figure 1) rupture brutale, RMSE de 0,27 à 0,05 en une élection. Cohérent avec l’effondrement du PC, l’émergence du FN et la droitisation du Parti radical [3]. Le modèle entraîné sur 1984–2007 est quasiment incapable de généraliser avant 1981 (RMSE $\in [0,20, 0,40]$).
- **2007–2012** : (Figure 2) rupture plus progressive, liée à la désindustrialisation, à la stratégie sarkozyste de droitisation et à la montée des enjeux identitaires.




FIGURE 3 – Matrice récapitulative des RMSE (modèles $\times$ années testées), toutes fenêtres d’entraînement. Encadrés noirs = périodes d’entraînement. Zones claires = enjeux similaires ; zones sombres = rupture de réalignement.

Trois régimes de déterminants socio-économiques

L’analyse par PI (variables géographiques et temporelles exclues) révèle une évolution profonde des déterminants du vote (Table 1). Les R^2 négatifs (définition machine learning) sont eux-mêmes un résultat : ils confirment que les variables socio-économiques *seules* sous-déterminent le vote, notamment hors des périodes de politique ordinaire où les enjeux symboliques et culturels dominent.




FIGURE 4 – PI des principales features à travers les ères électorales : *cadr_rank*, *suph/supf_rank*, *percommu*, *capitalimmo*, *pibtot*. Rouge = réalignement, vert = ordinaire, orange = ajustement. Chute de *cadr_rank* après 1981 ; montée du diplôme après 1977.

- Régime de classe (1962–1981).** Quatre variables dominant très nettement : *percommu* (navetteurs, $PI=14,4$), *peragglo* (pop. en agglom., $PI=10,8$), *cadr_rank* (part de cadres, $PI=7,6$), *pibtot* ($PI=5,0$). La *percommu* est un proxy de la modernisation économique : une commune où beaucoup de résidents font la navette est intégrée au marché du travail urbain-industriel. Vote à droite de la France des Trente Glorieuses, en opposition à la France ouvrière et agricole.
- Régime de brouillage (1981–2012).** Les réalignements successifs (effondrement du PCF, FN, cohabitations) dissolvent la lisibilité socio-économique. Les importances deviennent massivement négatives : un modèle entraîné sur 1962–1981 prédit à rebours le vote de 1988. Cela signifie que les variables qui prédisaient le vote à droite avant 1981 sont devenues contre-prédictives — la corrélation entre appartenance aux classes supérieures et vote à droite s’est brisée.
- Régime éducatif (2017–présent).** *suph_rank* ($PI=0,169$) et *supf_rank* ($PI=0,145$) dominant. Ce résultat valide quantitativement la thèse de [3] : nouvel ordre électoral structuré par le clivage éducatif. Les communes à forte proportion de diplômés votent pour le

centre-gauche et la gauche ; celles à faible niveau d’instruction penchent vers le RN et la droite modérée.

TABLE 1 – Performance par ère électorale (R=réalign., O=ordinaire, A=ajust.). Le $R^2 < 0$ confirme la sous-détermination socio-écon. du vote hors périodes ordinaires.

Ère	T	Test	R^2	RMSE
4 ^e phase (1958–62)	R	1969	−7,59	0,41
5 ^e phase (1981–84)	R	1988	−4,01	0,16
Ajust. 1973–74	A	1974	−519	0,42
Ajust. 1993–95	A	1995	−1,06	0,11
Préalign. 2012–17	O	2017	−2,46	0,18
Ord. post-5 ^e	O	2007	−0,46	0,07
Réalign. post-2017	R	2022	−2,54	0,17

Rôle de la géographie

L’impact des coordonnées (longitude/latitude) est non monotone : la géographie améliore les prédictions sur 1988–2017 ($\Delta R^2 = +0,47$ sur test 2012 ; $+0,31$ sur test 2022 avec longue fenêtre) mais devient *contre-productive* lors des reconfigurations : $\Delta R^2 = -0,32$ avec la fenêtre courte 2007–2017. La carte électorale héritée des décennies précédentes constitue alors un faux signal — les coordonnées retiennent la mémoire d’un ordre géographique révolu.

Lorsque la géographie est retirée, les variables de diplôme absorbent son signal : $\Delta \text{PI}(\text{supf_rank}) = +0,246$, $\Delta \text{PI}(\text{suph_rank}) = +0,122$, $\Delta \text{PI}(\text{electeurs_rank}) = +0,185$. Les coordonnées proxifient en réalité la **ségrégation éducative spatiale** : les diplômés du supérieur se concentrent dans les métropoles (Paris, Lyon, Bordeaux, Rennes, Montpellier) directement identifiables par leurs coordonnées. En l’absence de la géographie, c’est le diplôme qui prend le relais.

Enjeux locaux du vote extrême droite




FIGURE 5 – Carte de France : communes coloriées par pourcentage de vote extrême droite en 2022 (échelle jaune-vert). Bulles proportionnelles au nombre d’inscrits. Bastions historiques visibles : Nord, Grand Est, PACA.

Pour étudier ces spécificités locales, et valider quantitativement les observations de [1, 2], nous nous restreignons aux régions Nord, Grand Est (GE) et PACA, entre 2007 et 2022, avec agrégation départementale et une sélection de features pertinentes : PIB, revenus, chômage, capital immobilier, propriété. Une variable dummy sert de seuil de bruit.

Pour le **Nord** et le **GE**, le déterminant principal est l’évolution relative du **PIB communal** ($\text{PI} = 0,34$ et $0,41$ respectivement) : le vote ED est lié au déclin économique relatif [1]. Pour le Nord, le ratio et le percentile de revenus ressortent aussi ($\text{PI} = 0,26$ et $0,15$), suivis du chômage ($\text{PI} = 0,07$) et des variables d’immobilier. Ces résultats corroborent la narratif du déclassement économique dans des régions frappées par la désindustrialisation.

En **PACA**, la dynamique est structurellement opposée : la hausse des prix immobiliers et la concentration du capital sont associées à une hausse du vote ED (PI inter-régionale de **ratio PIB var%** : $-0,25$; **capital immo var%** : $-0,09$). La seule feature significative est la proportion de chômeurs ($\text{PI} = 0,12$, proche de la dummy $= 0,11$). Cela reflète une logique d’**exclusion foncière** sous pression de la gentrification et de l’immigration [2] : classes moyennes pressées par le bas (immigration économique) et par le haut (hausse de l’immobilier sur le littoral provençal).

L’analyse inter-régionale (modèle entraîné sur GE, PI sur PACA) confirme cette divergence : une même variable (variation du PIB) influence positivement le vote ED dans un sens en Grand Est et négativement en PACA. Ces spécificités locales opposées expliquent directement la prépondérance des variables géographiques à l’échelle nationale : les coordonnées capturent des dynamiques régionales contraires qui s’annulent à l’agrégation.

Conclusion

Ce projet démontre la faisabilité de la validation quantitative de théories de science politique par apprentissage automatique. Quatre résultats principaux :

- (i) Les ruptures électorales de **1981** et **2007** sont confirmées par leur signature RMSE, validant quantitativement la théorie des réalignements sur les législatives de la V^e République.
- (ii) Trois régimes successifs de déterminants : *classe* (1962–1981) → *brouillage* (1981–2012) → *éducation* (2017–présent).
- (iii) La géographie est un proxy de la ségrégation éducative spatiale ; elle devient un faux signal en période de reconfiguration.
- (iv) Des dynamiques territoriales opposées : déclin économique au Nord-Est, exclusion foncière au Sud-Est.

Les limites principales – R^2 négatifs hors période ordinaire, données manquantes pour 2024, tests limités aux législatives – ouvrent plusieurs prolongements : intégration des législatives 2024, test sur d’autres types d’élections (municipales, européennes), modèles capturant explicitement la non-stationnarité temporelle.

Références

- [1] B. Coquard, *Ceux qui restent*, Esprit, 2019.
- [2] F. Faury, *Des électeurs ordinaires : enquête sur la normalisation de l’extrême droite*, Seuil, 2024.
- [3] F. Gougou, *La consolidation d’un nouvel ordre électoral ?*, Rev. fr. sci. pol., 72(6), 915–943, 2024.
- [4] P. Martin, *Comprendre les évolutions électorales*, Presses de Sciences Po, 2000.
- [5] T. Piketty & J. Cagé, *Une histoire du conflit politique*, Seuil, 2023.